تنظیم دقیق مدلهای زبانی بزرگ (LLMs)

سوال ۱

هدف از این تمرین، تنظیم دقیق یک مدل GPT-2 برای تولید متنهای موضوعی بر اساس مجموعه دادهای از داستانهای کوتاه و مقایسه عملکرد این مدل در مقایسه با حالت بدون تنظیم دقیق است.

بخش اول - مجموعه داده

در این تمرین از مجموعه داده ای از داستانهای کوتاه برای تنظیم دقیق مدل استفاده می کنیم. شما می توانید از دیتاست Stories Datasets یا مجموعه داده مشابهی از منابع معتبر مانند Stories Dataset از دیتاست استفاده کنید. متنها را در قالب فایل txt. آماده کرده و اطمینان حاصل کنید که داده ها تمیز و فاقد ایراد هستند.

بخش دوم - پیادهسازی برای این تمرین مراحل زیر را انجام دهید:

- ۲ متنها را با استفاده از توکنایزر مربوط به مدل توکنایز کنید.
- ۳ مدل GPT-2 را با استفاده از Trainer API برای دادههای آموزشی تنظیم دقیق کنید.
- ۴ عملکرد مدل را در تولید متن با معیارهایی مانند تنوع 1 ، روانی 7 ، و انسجام 9 ارزیابی کنید.

بخش سوم - آزمایشات و سوالات

با توجه به مجموعه داده و مدل فوق، آزمایشات زیر را انجام داده و نتایج را در فایل گزارش ذکر کنید:

۱ - مقایسه خروجی مدل GPT-2 بدون تنظیم دقیق با نسخه تنظیم دقیقشده. چه تغییراتی در کیفیت تولید متن مشاهده میشود؟

diversity 1

fluency ⁷

coherence⁷

- ۲ با استفاده از مدل تنظیم دقیق شده، یک متن جدید تولید کنید و انسجام آن را تحلیل کنید.
 - ۳ تاثیر استفاده از تکنیکهای توقف زودهنگام ^۴ در بهبود عملکرد مدل را بررسی کنید.

نكات زير در انجام تمرينات الزامي است:

- ۱ پیادهسازیهای کامپیوتری را به زبان برنامهنویسی پایتون انجام دهید.
- ۲ بخش عمدهای از نمره تمرینات به گزارش تمرین اختصاص دارد و ارسال برنامهها بدون گزارش فاقد ارزش است. در تهیه گزارش دقت نمایید که تمام اطلاعات، تصاویر و نمودارهای مورد نیاز برای اثبات پاسخها مبتنی بر آزمایشات خواسته شده در تمرین، بطور کامل و دقیق ذکر شده باشند.
- ۳ مطابق قوانین دانشگاه هر نوع کپیبرداری و اشتراک کار دانشجویان غیرمجاز است. در صورت مشاهده چنین مواردی، با طرفین شدیدا برخورد خواهد شد.
- ۴ استفاده از کدها و توضیحات اینترنت یا کدها و توضیحات تولید شده با مدلهای هوش مصنوعی به منظور یادگیری بلامانع است، اما کپیبرداری و انجام تمرینات توسط این ابزارها غیرمجاز است. در صورتی که از چنین ابزارهایی بهره می گیرید، حتما به تمام جزئیات و نکات مرتبط با پاسخها مسلط باشید، در غیر اینصورت نمره کل تمرین را از دست خواهید داد.
- ۵ در صورت نیاز می توانید سوالات خود را در خصوص پروژه از تدریسیارهای درس، به ایمیل زیر ارسال نموده یا در گروه «بله» مطرح نمایید.

ann.ceit.aut@gmail.com

۶- فایلهای کد و گزارش خود را در قالب یک فایل فشرده با فرمت StudentID_HW08.zip تا تاریخ ۱۴۰۳/۱۱/۱۳ فقط در بخش مربوطه در سایت درس بارگذاری نمایید. توجه نمایید، هر روز تاخیر منجر به کسر ۱۰ درصد از نمره پروژه می شود.

early stopping *